

**LAPORAN UJIAN AKHIR SEMESTER
KECERDASAN ARTIFISIAL PADA BISNIS**

**Analisis Pemilihan 5 Saham Portofolio Warren Buffett Menggunakan Ensemble
TimesFM 2.5, RandomForest, CatBoost, dan Analisis Portofolio Risk-Aware Berbasis
Literatur**



**Oleh :
Aisya Ulul Asmi
25/564969/PPA/07123**

**PROGRAM MAGISTER KECERDASAN ARTIFISIAL
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
2026**

1. Pendahuluan

1.1 Latar Belakang Bisnis dan Peran AI

Dalam skenario bisnis, perusahaan manajer investasi Indonesia perlu mengalihkan sebagian dana ke saham Amerika Serikat karena kondisi pasar domestik diasumsikan melemah. Permasalahan bisnisnya bukan sekadar memprediksi harga saham, melainkan menentukan saham mana yang layak dibeli, berapa bobotnya, dan bagaimana risiko portofolio dikendalikan ketika keputusan melibatkan dana besar. Oleh karena itu, pendekatan AI diposisikan sebagai sistem pendukung keputusan, bukan sebagai mesin otomatis yang menggantikan analisis manusia.

Pemilihan universe dari top holding Warren Buffett memberi batasan awal yang logis karena daftar tersebut merepresentasikan saham besar, likuid, dan memiliki rekam jejak bisnis yang relatif kuat. Namun, saham yang baik secara fundamental tidak selalu menjadi pilihan terbaik untuk horizon 6 bulan. Karena itu, laporan ini mengombinasikan prediksi return, probabilitas BUY, risiko, likuiditas, posisi harga, dan stress test agar keputusan portofolio lebih seimbang.

1.2 Rumusan Masalah

1. Bagaimana mendeskripsikan seluruh dataset yang digunakan agar proses eksperimen dapat dipahami dan direplikasi?
2. Bagaimana preprocessing dan feature engineering dilakukan pada data saham berbentuk time series?
3. Bagaimana model TimesFM, RandomForest, CatBoostRegressor, CatBoostClassifier, dan ensemble digunakan untuk menghasilkan proyeksi 6 bulan?
4. Bagaimana hasil prediksi, visualisasi forecast panel, ranking, alokasi, benchmark, dan stress test dianalisis secara deskriptif?
5. Bagaimana hasil AI diterjemahkan menjadi rekomendasi portofolio yang relevan bagi keputusan bisnis?

1.3 Tujuan

1. Menyusun laporan akademik yang lebih lengkap, deskriptif, dan mudah dibaca berdasarkan review dosen.
2. Menjelaskan fungsi setiap dataset, tahapan preprocessing, dan kelompok fitur yang digunakan.
3. Menjelaskan model AI satu per satu secara lebih proper dan terstruktur.
4. Menampilkan seluruh forecast panel untuk 10 saham beserta analisis masing-masing visualisasi.
5. Memberikan analisis mendalam pada hasil evaluasi model, ranking saham, alokasi portofolio, benchmark, sector exposure, stress test, dan implikasi manajerial.

2. Dataset dan Deskripsi Data

2.1 Deskripsi Masing-Masing Dataset

Bagian ini ditambahkan agar pembaca mengetahui peran setiap dataset dalam pipeline. Dataset tidak hanya terdiri dari data mentah harga saham, tetapi juga dataset gabungan, dataset hasil feature engineering, dataset modeling, serta dataset output prediksi dan portofolio. Pemisahan ini penting karena setiap tahap memiliki fungsi yang berbeda dalam eksperimen AI.

Dataset	Lokasi File	Kolom Utama	Deskripsi dan Fungsi
Raw per ticker CSV	data/raw/{ticker}.csv	Date, Open, High, Low, Close, Volume, Ticker	Data harga historis harian per saham. Dipakai sebagai sumber utama sebelum digabung. Harga sudah berada pada bentuk adjusted hasil unduhan yfinance sehingga lebih aman terhadap split/dividend adjustment.
Clean stock data gabungan	data/processed/all_stocks.csv	Date, OHLCV, Ticker	Gabungan seluruh saham kandidat dalam format long panel. Dataset ini memudahkan group-by per ticker untuk feature engineering dan validasi konsistensi tanggal.
Close price matrix	project_submission/dataset/processed/close_price_matrix_5y.csv	Date + 10 kolom harga close	Dataset wide format untuk melihat perbandingan harga penutupan antar saham, visualisasi historis, dan pemeriksaan cepat terhadap missing date.
Features all	data/processed/features_all.csv	OHLCV, indikator teknikal, target 20D/60D/120D	Dataset hasil feature engineering sebelum drop NA penuh. Baris awal masih mengandung NA karena rolling window 20, 60, 100, dan 252 hari.
Modeling dataset	data/processed/modeling_dataset.csv	45 fitur model + target return	Dataset final untuk training dan validasi model setelah baris dengan target/fitur tidak lengkap dihapus. Ini adalah dataset yang benar-benar masuk ke model ML.
Forecast outputs	outputs/tables/forecast_summary_6m.csv	return model, bobot ensemble, risiko, probabilitas BUY	Ringkasan hasil prediksi terbaru per saham pada horizon 120 trading days. Dipakai untuk ranking, seleksi, dan alokasi portofolio.
Portfolio outputs	outputs/tables/portfolio_allocation.csv	ticker, bobot, alokasi IDR, projected profit	Dataset hasil keputusan akhir yang menerjemahkan skor AI menjadi bobot dan nominal investasi.

Tabel 1. Deskripsi masing-masing dataset yang digunakan dalam eksperimen.

2.2 Ringkasan Historis 10 Saham

Ringkasan historis menunjukkan bahwa setiap saham memiliki jumlah observasi yang sama, yaitu 2.119 hari perdagangan. Keseragaman jumlah baris ini penting karena mengurangi risiko bias akibat perbedaan panjang historis data. Dari sisi historis 6 bulan terakhir, OXY dan CVX menunjukkan return tinggi, tetapi keduanya tidak otomatis terpilih karena model juga mempertimbangkan proyeksi return ke depan, risk score, probabilitas BUY, dan drawdown. KHC memiliki max drawdown besar, sedangkan OXY memiliki drawdown paling ekstrem, sehingga keduanya perlu diperlakukan hati-hati dalam alokasi.

Ticker	Start	End	Rows	Last Close	Return Historis 6M	Volatilitas 60D	Max Drawdown
AAPL	2018-01-02	2026-06-08	2119	310.52	11.79%	1.38%	-38.52%
AXP	2018-01-02	2026-06-08	2119	312.70	-17.82%	1.47%	-49.64%
BAC	2018-01-02	2026-06-08	2119	53.71	-1.53%	1.33%	-48.95%
CB	2018-01-02	2026-06-08	2119	322.77	4.94%	1.11%	-42.59%
CVX	2018-01-02	2026-06-08	2119	189.46	28.72%	1.64%	-55.77%
GOOGL	2018-01-02	2026-06-08	2119	364.52	17.94%	2.29%	-44.32%
KHC	2018-01-02	2026-06-08	2119	23.23	-1.67%	1.58%	-72.00%
KO	2018-01-02	2026-06-08	2119	79.33	13.27%	1.18%	-36.99%
MCO	2018-01-02	2026-06-08	2119	443.83	-8.38%	1.50%	-42.02%
OXY	2018-01-02	2026-06-08	2119	57.37	40.34%	2.45%	-88.39%

Tabel 2. Ringkasan data historis per saham.

Analisis dataset historis

- Dataset raw memiliki frekuensi harian sehingga sesuai untuk analisis time-series dan feature engineering berbasis rolling window.
- Kesamaan periode dan jumlah baris antar saham membuat perbandingan return, volatilitas, dan drawdown menjadi lebih fair.
- Perbedaan karakter antar saham terlihat jelas: AAPL/GOOGL memiliki profil growth, KO/CB relatif defensif, sedangkan OXY/CVX sangat dipengaruhi siklus energi.
- Nilai max drawdown memberi konteks penting bahwa expected return tinggi tidak selalu berarti risiko rendah.

3. Preprocessing dan Feature Engineering

3.1 Preprocessing Data

Preprocessing dilakukan untuk memastikan data yang masuk ke model memiliki struktur yang konsisten dan tidak mengandung informasi masa depan. Penjelasan berikut disusun dengan penomoran agar prosesnya lebih mudah dibaca.

1. Pengumpulan data: data OHLCV harian untuk 10 saham dikumpulkan dari cache yfinance dan disimpan per ticker dalam format CSV.
2. Penyatuan data: seluruh file raw digabung menjadi all_stocks.csv dengan format long panel sehingga setiap baris merepresentasikan satu tanggal dan satu ticker.
3. Standarisasi kolom: kolom utama yang dipertahankan adalah Date, Open, High, Low, Close, Volume, dan Ticker.
4. Pengurutan waktu: data setiap ticker diurutkan berdasarkan Date agar semua rolling calculation dan target forward return berjalan sesuai urutan waktu.
5. Validasi kelengkapan: jumlah observasi diperiksa per ticker. Seluruh saham memiliki 2.119 observasi, sehingga tidak ada saham yang memiliki horizon historis lebih pendek.
6. Penanganan missing value awal: nilai NA yang muncul karena perhitungan rolling window tidak langsung dihapus pada features_all.csv agar proses feature audit tetap dapat dilakukan.
7. Pembentukan modeling dataset: baris yang masih memiliki NA pada fitur model dan target return 20D, 60D, atau 120D dihapus untuk menghasilkan modeling_dataset.csv.
8. Time-based split: pembagian training dan testing dilakukan berdasarkan urutan waktu, bukan random split, agar pola masa depan tidak bocor ke masa lalu.
9. Pencegahan data leakage: semua fitur rolling dihitung dari data historis sampai tanggal observasi, sedangkan target return dihitung dari harga masa depan hanya sebagai label, bukan sebagai input fitur.
10. Validasi output: hasil preprocessing dicek melalui jumlah baris, kolom fitur, target, tabel ringkasan, dan konsistensi ticker.

3.2 Feature Engineering

Feature engineering bertujuan mengubah data harga mentah menjadi informasi yang lebih kaya bagi model AI. Karena harga saham bersifat noisy, model tidak hanya diberi harga close, tetapi juga indikator momentum, tren, volatilitas, likuiditas, posisi harga, dan target return multi-horizon.

1. Return features: return_1d, return_5d, return_10d, return_20d, dan log_return_1d digunakan untuk menangkap perubahan harga dalam beberapa horizon pendek.
2. Price action features: price_change, high_low_spread, dan open_close_spread menggambarkan tekanan intraday dan jarak pergerakan harga harian.
3. Trend moving average features: sma_5, sma_10, sma_20, sma_50, sma_100, ema_12, dan ema_26 mengukur apakah harga berada di atas atau di bawah tren jangka pendek hingga menengah.
4. Momentum indicators: RSI, MACD, MACD signal, MACD histogram, momentum_10, ROC 10/20/60, stochastic oscillator, Williams %R, dan CCI digunakan untuk membaca kekuatan tren atau kondisi overbought/oversold.

5. Volatility features: rolling_std_10, rolling_std_20, rolling_std_60, ATR 14, dan Bollinger bandwidth menangkap risiko fluktuasi harga.
6. Trend strength features: ADX 14 dan Donchian position membantu membaca kekuatan arah tren dan posisi harga dalam channel harga.
7. Risk-adjusted return features: sharpe_20 dan sharpe_60 mengukur kualitas return relatif terhadap volatilitas.
8. Volume and liquidity features: volume_change, volume_sma_20, volume_zscore_20, dollar_volume_20, dan OBV mengukur aktivitas transaksi dan dukungan volume terhadap pergerakan harga.
9. 52-week position features: close_to_52w_high, close_to_52w_low, dan price_position_252d digunakan untuk membedakan saham yang dekat dengan titik tinggi, titik rendah, atau posisi tengah dalam satu tahun perdagangan.
10. Target variables: target_return_20d, target_return_60d, dan target_return_120d digunakan sebagai label forward return untuk model multi-horizon, dengan target utama laporan adalah 120 trading days.
11. Risk output features: drawdown dan volatility_60d digunakan untuk membaca risiko terbaru dan membantu membentuk risk score dalam ranking portofolio.

Analisis feature engineering

- Fitur teknikal tidak digunakan sebagai sinyal tunggal, tetapi sebagai kumpulan variabel yang memungkinkan model membaca pola non-linear.
- Fitur posisi 52 minggu penting untuk menerjemahkan instruksi BUY saat lowest dan HOLD/sell saat highest ke dalam bentuk kuantitatif.
- Fitur volatilitas dan drawdown mencegah model terlalu agresif memilih saham hanya karena return historis atau proyeksi return tinggi.
- Fitur likuiditas relevan karena modal simulasi besar, sehingga saham dengan dollar volume lebih baik lebih aman untuk eksekusi.

4. Model AI yang Digunakan

4.1 Model 1 - TimesFM 2.5

TimesFM 2.5 digunakan sebagai model time-series foundation model untuk menghasilkan proyeksi jalur harga pada horizon 120 trading days. Model ini membaca deret harga historis dan menghasilkan prediksi masa depan berbasis pola temporal. Dalam pipeline, TimesFM memberi kontribusi 30% pada ensemble final. Fungsi utamanya adalah memberikan sinyal time-series murni yang tidak bergantung pada feature engineering tabular.

Secara analitis, TimesFM berperan sebagai anchor konservatif. Pada beberapa saham, prediksi TimesFM lebih rendah daripada RandomForest dan CatBoost, misalnya AAPL. Hal ini mengurangi

risiko over-optimism dari model tabular. Jika TimesFM sangat berbeda dari model lain, forecast consistency akan menurun dan interpretasi risiko perlu lebih hati-hati.

4.2 Model 2 - RandomForestRegressor

RandomForestRegressor digunakan untuk memprediksi return 20D, 60D, dan 120D berdasarkan fitur tabular hasil feature engineering. RandomForest cocok untuk baseline non-linear karena membangun banyak decision tree dan merata-ratakan hasilnya. Model ini relatif robust terhadap hubungan non-linear, outlier moderat, dan interaksi antar fitur.

Dalam laporan ini, RandomForest membantu menangkap pola seperti hubungan antara volatilitas, posisi harga 52 minggu, momentum, dan return masa depan. Namun, RandomForest dapat kurang responsif terhadap perubahan rezim pasar karena pola yang dipelajari berasal dari data historis. Oleh sebab itu, hasilnya tidak digunakan secara tunggal, tetapi digabung dengan CatBoost dan TimesFM.

4.3 Model 3 - CatBoostRegressor

CatBoostRegressor digunakan sebagai model gradient boosting untuk memprediksi return masa depan. Model boosting membangun pohon secara bertahap untuk memperbaiki error model sebelumnya. Dalam konteks dataset finansial, CatBoost sering berguna untuk menangkap pola non-linear yang lebih tajam dibanding baseline tree ensemble biasa.

Pada beberapa saham, CatBoost memberikan proyeksi return yang lebih agresif dibanding TimesFM. Contohnya MCO dan AAPL, di mana CatBoost membaca peluang return tinggi berdasarkan kombinasi fitur momentum, risk-adjusted score, posisi harga, dan sinyal teknikal. Karena model boosting dapat lebih sensitif terhadap noise, bobotnya dikombinasikan dengan RF dan TimesFM agar keputusan akhir lebih stabil.

4.4 Model 4 - CatBoostClassifier

CatBoostClassifier tidak digunakan untuk memprediksi besar return, melainkan memprediksi probabilitas return 120D bernilai positif. Output ini disebut Buy Probability atau probabilitas BUY. Probabilitas ini penting karena return forecast yang tinggi tetapi probabilitas arah positif rendah akan lebih berisiko. Dengan demikian, classifier menjadi sinyal probablistik yang melengkapi model regresi.

Metrik classifier harus dibaca secara hati-hati. Rata-rata accuracy dan ROC-AUC tidak menunjukkan model sempurna, tetapi cukup sebagai weak signal ketika dikombinasikan dengan expected return, risk score, dan benchmark. KHC, misalnya, memiliki probabilitas BUY tinggi pada latest prediction, tetapi performa classifier historisnya tidak stabil. Oleh karena itu, KHC diberi sinyal HOLD dan diperlakukan sebagai tactical opportunity, bukan core holding agresif.

4.5 Model 5 - Ensemble Forecast

Ensemble digunakan untuk menggabungkan TimesFM, RandomForest, dan CatBoostRegressor. TimesFM diberi bobot tetap 30%, sedangkan bobot RandomForest dan CatBoost disesuaikan berdasarkan performa RMSE. Prinsipnya, model dengan RMSE lebih rendah memperoleh bobot lebih

besar. Pendekatan ini dipilih karena financial forecasting memiliki noise tinggi, sehingga mengandalkan satu model saja berisiko menghasilkan rekomendasi yang terlalu bias.

Secara bisnis, ensemble lebih sesuai sebagai decision support karena hasilnya lebih stabil dan lebih mudah dipertanggungjawabkan. Jika tiga model sepakat, confidence terhadap arah prediksi meningkat. Jika model saling bertentangan, hasil akhir tetap dapat dipakai, tetapi harus diberi interpretasi risiko lebih hati-hati melalui forecast consistency dan stress test.

Analisis metodologis model AI

- Rata-rata performa Ensemble pada testing memiliki MAE 0.161, RMSE 0.197, dan DSTAT 57.49%.
- Directional accuracy di atas 50% menunjukkan model memiliki sinyal arah, tetapi belum cukup untuk dijadikan keputusan otomatis tanpa risk management.
- Kombinasi regresi, klasifikasi, dan time-series foundation model membuat pipeline lebih kaya karena setiap pendekatan membaca data dari sudut pandang berbeda.
- Model dipakai untuk ranking relatif antar saham, bukan untuk mengklaim prediksi harga yang pasti.

5. Hasil Eksperimen dan Analisis

5.1 Evaluasi Model Regresi

Evaluasi regresi menggunakan MAE, RMSE, dan DSTAT. MAE dan RMSE mengukur kesalahan prediksi return 120D, sedangkan DSTAT mengukur kemampuan model membaca arah return positif atau negatif. Dalam konteks saham, DSTAT sering lebih relevan untuk keputusan bisnis dibanding prediksi harga yang sangat presisi, karena tujuan portofolio adalah memilih saham yang relatif lebih prospektif.

Ticker	MAE	RMSE	DSTAT
AAPL	0.115	0.138	60.56%
AXP	0.157	0.177	58.17%
KO	0.050	0.058	67.73%
BAC	0.140	0.179	52.59%
CVX	0.126	0.178	66.14%
MCO	0.091	0.115	47.81%
OXY	0.273	0.335	52.99%
CB	0.065	0.076	58.96%
KHC	0.132	0.144	56.18%
GOOGL	0.456	0.566	53.78%

Tabel 3. Evaluasi model Ensemble per saham.

Hasil menunjukkan bahwa performa model tidak seragam antar saham. KO, AAPL, dan CVX memiliki DSTAT relatif tinggi pada evaluasi test, sedangkan MCO lebih rendah walaupun proyeksi

return terbarunya tinggi. Hal ini memperlihatkan bahwa keputusan akhir tidak boleh hanya bergantung pada satu metrik. Saham dengan potensi return tinggi tetap perlu dibatasi bobotnya bila performa historis model atau stress test menunjukkan risiko tertentu.

5.2 Evaluasi CatBoostClassifier

Ticker	Accuracy	Precision BUY	Recall BUY	F1 BUY	ROC-AUC
AAPL	0.786	0.805	0.922	0.859	0.753
AXP	0.456	0.552	0.526	0.539	0.352
KO	0.825	0.957	0.809	0.877	0.918
BAC	0.500	0.916	0.390	0.547	0.709
CVX	0.460	0.936	0.404	0.564	0.632
MCO	0.504	0.525	0.905	0.665	0.502
OXY	0.520	0.661	0.291	0.404	0.585
CB	0.782	0.791	0.969	0.871	0.727
KHC	0.052	0.016	1.000	0.032	0.450
GOOGL	0.302	0.679	0.352	0.463	0.189

Tabel 4. Evaluasi CatBoostClassifier per saham.

Classifier menunjukkan hasil yang bervariasi. AAPL, KO, dan CB memiliki accuracy dan ROC-AUC yang lebih baik, sehingga probabilitas BUY pada saham-saham tersebut lebih mudah dipertanggungjawabkan. Sebaliknya, KHC dan GOOGL memiliki metrik classifier historis yang lemah, sehingga probabilitas BUY terbaru harus dianggap sebagai sinyal tambahan, bukan bukti kuat. Dengan framing ini, laporan menghindari klaim berlebihan dan menempatkan classifier sebagai bagian dari decision scoring.

5.3 Walk-Forward Validation

Ticker	Window	Avg MAE	Avg RMSE	Avg Dir. Acc.	Hit Rate vs EW	Actual Excess 120D
AAPL	3	0.146	0.186	33.83%	56.60%	2.44%
AXP	3	0.169	0.211	37.58%	71.34%	6.17%
BAC	3	0.140	0.175	34.76%	66.09%	3.32%
CB	3	0.088	0.102	33.37%	58.50%	0.81%
CVX	3	0.121	0.141	34.58%	28.59%	-3.53%
GOOGL	3	0.213	0.266	34.79%	75.05%	15.25%
KHC	3	0.092	0.106	33.95%	6.29%	-13.32%
KO	3	0.089	0.108	31.39%	35.26%	-2.53%
MCO	3	0.100	0.123	33.43%	61.47%	-0.20%
OXY	3	0.170	0.210	32.51%	18.26%	-8.42%

Tabel 5. Ringkasan walk-forward validation.

Walk-forward validation digunakan untuk melihat ketahanan model pada beberapa window out-of-sample. Hasilnya menunjukkan bahwa beberapa saham seperti GOOGL, AXP, BAC, dan MCO memiliki hit rate vs equal-weight yang cukup baik, sedangkan KHC, OXY, KO, dan CVX lebih lemah pada window historis tertentu. Artinya, model tidak selalu stabil pada semua saham dan semua rezim pasar. Temuan ini justru penting secara akademik karena menunjukkan bahwa sistem dievaluasi secara kritis, bukan hanya menampilkan hasil akhir yang terlihat menguntungkan.

5.4 Prediksi 6 Bulan dan Ranking Saham

Ticker	Last Price	Pred. Price 6M	Ens. Return	TimesFM Return	RF Return	CatBoos t Return	Excess Return	BUY Prob.	Consistency
AAPL	310.52	336.24	8.28%	-0.23%	9.68%	13.88%	5.47%	98.07%	0.67
AXP	312.70	335.18	7.19%	5.80%	8.73%	6.55%	4.37%	28.72%	1.00
KO	79.33	81.75	3.05%	0.17%	3.54%	4.95%	0.23%	17.72%	1.00
BAC	53.71	48.87	-9.00%	2.37%	-11.50%	-16.58%	-11.82%	25.17%	0.33
CVX	189.46	177.19	-6.48%	-4.40%	-9.72%	-4.98%	-9.30%	9.29%	0.00
MCO	443.83	516.17	16.30%	6.16%	19.81%	21.72%	13.48%	91.25%	1.00
OXY	57.37	49.47	-13.76%	-2.22%	-21.18%	-16.32%	-16.58%	4.33%	0.00
CB	322.77	339.61	5.22%	2.23%	5.94%	6.97%	2.40%	83.33%	1.00
KHC	23.23	25.77	10.96%	4.83%	17.89%	9.84%	8.14%	90.64%	1.00
GOOGL	364.52	387.97	6.43%	5.67%	4.90%	8.65%	3.61%	94.70%	1.00

Tabel 6. Ringkasan prediksi 6 bulan seluruh saham.

Prediksi 6 bulan menunjukkan perbedaan besar antar saham. MCO memiliki expected return tertinggi sebesar 16,30%, diikuti KHC sebesar 10,96%, AAPL sebesar 8,28%, AXP sebesar 7,19%, dan GOOGL sebesar 6,43%. Namun, pemilihan portofolio tidak sekadar mengambil lima return tertinggi. CB tetap dipilih walaupun expected return-nya lebih rendah karena risk score rendah dan fungsinya sebagai stabilizer. Sebaliknya, AXP tidak terpilih walaupun return-nya positif karena probabilitas BUY latest dan ranking score kalah dari kandidat terpilih.

Rank	Ticker	Exp. Return	Excess	BUY Prob.	Risk	Rank Score	Signal	Selected
1	AAPL	8.28%	5.47%	98.07%	0.118	0.821	BUY	Ya
2	KHC	10.96%	8.14%	90.64%	0.516	0.762	HOLD	Ya
3	MCO	16.30%	13.48%	91.25%	0.195	0.674	BUY	Ya
4	GOOGL	6.43%	3.61%	94.70%	0.513	0.662	BUY	Ya
5	KO	3.05%	0.23%	17.72%	0.028	0.631	HOLD	Tidak
6	CB	5.22%	2.40%	83.33%	0.055	0.603	BUY	Ya
7	AXP	7.19%	4.37%	28.72%	0.260	0.556	HOLD	Tidak
8	CVX	-6.48%	-9.30%	9.29%	0.383	0.400	HOLD	Tidak
9	BAC	-9.00%	-11.82%	25.17%	0.201	0.301	HOLD	Tidak

Rank	Ticker	Exp. Return	Excess	BUY Prob.	Risk	Rank Score	Signal	Selected
10	OXY	-13.76%	-16.58%	4.33%	1.000	0.106	HOLD	Tidak

Tabel 7. Ranking saham dan keputusan seleksi.


5.5 Alokasi Portofolio Final

Ticker	Signal	Exp Return	Bobot	Alokasi IDR	Projected Profit	Sektor
MCO	BUY	16.30%	25.00%	Rp250.000.000.000	Rp40.751.815.973	Financial Services
AAPL	BUY	8.28%	19.72%	Rp197.218.011.038	Rp16.338.487.599	Technology
GOOGL	BUY	6.43%	16.66%	Rp166.553.039.530	Rp10.711.761.656	Communication Services
CB	BUY	5.22%	18.43%	Rp184.298.347.221	Rp9.616.339.373	Insurance
KHC	HOLD	10.96%	20.19%	Rp201.930.602.210	Rp22.128.934.709	Consumer Staples

Tabel 8. Alokasi portofolio final.

Portofolio final memilih MCO, AAPL, GOOGL, CB, KHC. Bobot tertinggi diberikan kepada MCO sebesar 25,00% karena expected return dan expected excess return tertinggi, tetapi bobotnya dibatasi oleh cap maksimum untuk mencegah konsentrasi risiko. KHC memperoleh bobot 20,19% meskipun sinyalnya HOLD karena model masih melihat peluang return, tetapi karakter risikonya lebih tinggi. AAPL, GOOGL, dan CB melengkapi portofolio melalui kombinasi core holding, growth exposure, dan stabilizer risiko.

Alokasi Portofolio Balanced Risk-Aware



Gambar 1. Alokasi portofolio final balanced risk-aware.

Secara nominal, projected profit sebesar Rp99.547.339.309 tampak besar karena modal awal Rp1 triliun. Namun, expected return sebesar 9.95%. Ini menunjukkan bahwa proyeksi laba harus selalu dibaca sebagai proporsi return berbasis model dan bukan sebagai kepastian hasil investasi.

5.6 Benchmark, Sector Exposure, dan Stress Test

Strategi	Expected Return	Excess vs Universe	Catatan
Risk-aware selected portfolio	9.95%	7.14%	Bobot mengikuti allocation score, risiko, dan cap portofolio.
Equal-weight all 10 candidates	2.82%	0.00%	Benchmark internal karena tidak memakai data SPY eksternal.
Equal-weight top 5 by ranking score	9.00%	6.19%	Baseline sederhana tanpa optimasi bobot.

Tabel 9. Perbandingan dengan benchmark internal.

Portofolio risk-aware mengungguli equal-weight 10 kandidat dan equal-weight top 5 berdasarkan expected return. Ini menunjukkan bahwa pembobotan berbasis allocation score memberi nilai tambah dibanding sekadar membagi bobot sama rata. Namun, benchmark internal belum cukup untuk menyimpulkan portofolio mengalahkan pasar AS secara luas. Karena itu, evaluasi lanjutan sebaiknya menambahkan SPY/S&P 500, BRK-B, dan QQQ sebagai benchmark eksternal.

Sektor	Bobot
Financial Services	25.00%
Consumer Staples	20.19%
Technology	19.72%
Insurance	18.43%
Communication Services	16.66%

Tabel 10. Sector exposure portofolio.

Sector exposure menunjukkan portofolio tidak terkonsentrasi penuh pada satu sektor. Financial Services memiliki bobot terbesar karena MCO, sedangkan Technology, Communication Services, Insurance, dan Consumer Staples tetap hadir sebagai diversifikasi. Tidak adanya sektor Energy dalam portofolio menandakan bahwa model tidak memilih CVX dan OXY meskipun keduanya pernah memiliki return historis 6 bulan tinggi. Keputusan ini konsisten dengan pendekatan risk-aware karena OXY memiliki risk score tertinggi dan drawdown historis paling dalam.

Skenario	Start	End	Return Port.	Return EW	Excess	Worst Stock	Worst Return
COVID crash	2020-02-19	2020-03-23	-34.04%	-42.98%	8.94%	OXY	-76.51%


Skenario	Start	End	Return Port.	Return EW	Excess	Worst Stock	Worst Return
proxy							
2022 rate shock proxy	2022-01-03	2022-10-14	-19.43%	0.76%	-20.18%	MCO	-38.25%
Recent test window	2024-12-11	2025-12-12	10.98%	11.98%	-1.00%	KHC	-17.18%

Tabel 11. Stress test historis.

Stress test memperlihatkan bahwa portofolio tidak selalu unggul pada semua rezim pasar. Pada skenario COVID crash, portofolio lebih defensif dibanding equal-weight universe. Pada skenario 2022 rate shock, portofolio underperform karena MCO sensitif terhadap kenaikan suku bunga. Pada recent test window, portofolio sedikit kalah dari equal-weight universe. Dengan demikian, hasil model perlu dipantau secara berkala dan tidak boleh diperlakukan sebagai strategi statis.

5.7 Visualisasi Forecast Panel Seluruh Saham

5.7.1 Forecast Panel AAPL




Gambar 2. Forecast panel AAPL.

AAPL memperlihatkan pola core holding yang kuat. Ensemble memproyeksikan return positif 8,28% dengan probabilitas BUY sangat tinggi 98,07%. TimesFM lebih konservatif dibanding RF dan CatBoost, sehingga ensemble tidak terlalu agresif. Visualisasi ini menunjukkan bahwa AAPL berada dekat area 52-week high, sehingga peluang upside tetap ada tetapi ruang buy-low terbatas. Karena likuiditas tinggi dan risk score rendah, AAPL layak menjadi komponen inti portofolio.

Ringkasan numerik AAPL: harga terakhir 310.52, prediksi harga 6 bulan 336.24, ensemble return 8.28%, TimesFM return -0.23%, RF return 9.68%, CatBoost return 13.88%, probabilitas BUY 98.07%, dan forecast consistency 0.67. Angka-angka ini menjelaskan mengapa visualisasi perlu dibaca bersama ranking dan risk score, bukan secara terpisah.

5.7.2 Forecast Panel AXP




Gambar 3. Forecast panel AXP.

AXP memiliki proyeksi return positif 7,19%, tetapi probabilitas BUY hanya 28,72%. Forecast panel mengindikasikan adanya potensi pemulihan harga, tetapi sinyal klasifikasi tidak cukup kuat. Hal ini menjelaskan mengapa AXP tidak masuk portofolio final meskipun expected return-nya positif. Secara bisnis, AXP lebih tepat dipantau sebagai watchlist daripada langsung diberi alokasi.

Ringkasan numerik AXP: harga terakhir 312.70, prediksi harga 6 bulan 335.18, ensemble return 7.19%, TimesFM return 5.80%, RF return 8.73%, CatBoost return 6.55%, probabilitas BUY 28.72%, dan forecast consistency 1.00. Angka-angka ini menjelaskan mengapa visualisasi perlu dibaca bersama ranking dan risk score, bukan secara terpisah.

5.7.3 Forecast Panel BAC




Gambar 4. Forecast panel BAC.

BAC menunjukkan forecast negatif sebesar -9,00%. Walaupun TimesFM masih membaca return positif kecil, RF dan CatBoost memberikan sinyal negatif yang lebih dominan. Visualisasi ini mengindikasikan ketidaksepakatan model, tetapi ensemble akhirnya condong bearish. Karena expected excess return negatif dan probabilitas BUY rendah, BAC dieliminasi dari portofolio.

Ringkasan numerik BAC: harga terakhir 53.71, prediksi harga 6 bulan 48.87, ensemble return -9.00%, TimesFM return 2.37%, RF return -11.50%, CatBoost return -16.58%, probabilitas BUY 25.17%, dan

forecast consistency 0.33. Angka-angka ini menjelaskan mengapa visualisasi perlu dibaca bersama ranking dan risk score, bukan secara terpisah.

5.7.4 Forecast Panel CB




Gambar 5. Forecast panel CB.

CB menunjukkan proyeksi return 5,22% dengan probabilitas BUY 83,33% dan risk score sangat rendah. Forecast panel tidak seagresif MCO atau KHC, tetapi jalur prediksinya lebih stabil. Ini menjelaskan peran CB sebagai stabilizer portofolio. Saham ini dipilih bukan karena return tertinggi, melainkan karena kombinasi risiko rendah, probabilitas positif, dan diversifikasi sektor Insurance.

Ringkasan numerik CB: harga terakhir 322.77, prediksi harga 6 bulan 339.61, ensemble return 5.22%, TimesFM return 2.23%, RF return 5.94%, CatBoost return 6.97%, probabilitas BUY 83.33%, dan forecast consistency 1.00. Angka-angka ini menjelaskan mengapa visualisasi perlu dibaca bersama ranking dan risk score, bukan secara terpisah.

5.7.5 Forecast Panel CVX




Gambar 6. Forecast panel CVX.

CVX memiliki ensemble return negatif -6,48% meskipun return historis 6 bulan terakhir cukup tinggi. Forecast panel menunjukkan model tidak melihat kelanjutan momentum positif ke depan. Probabilitas

BUY hanya 9,29%, sehingga risiko masuk pada fase yang kurang menarik cukup besar. Karena sektor Energy juga sensitif terhadap harga komoditas, CVX tidak dipilih dalam skenario balanced risk-aware.

Ringkasan numerik CVX: harga terakhir 189.46, prediksi harga 6 bulan 177.19, ensemble return -6.48%, TimesFM return -4.40%, RF return -9.72%, CatBoost return -4.98%, probabilitas BUY 9.29%, dan forecast consistency 0.00. Angka-angka ini menjelaskan mengapa visualisasi perlu dibaca bersama ranking dan risk score, bukan secara terpisah.

5.7.6 Forecast Panel GOOGL




Gambar 7. Forecast panel GOOGL.

GOOGL memiliki expected return positif 6,43% dan probabilitas BUY sangat tinggi 94,70%. Forecast panel menunjukkan adanya potensi kenaikan, tetapi volatilitas 60D juga tertinggi kedua setelah OXY. Karena itu, GOOGL tetap dipilih tetapi dengan bobot lebih terkontrol. Saham ini memberi exposure growth dan communication services, namun tidak mendominasi portofolio.

Ringkasan numerik GOOGL: harga terakhir 364.52, prediksi harga 6 bulan 387.97, ensemble return 6.43%, TimesFM return 5.67%, RF return 4.90%, CatBoost return 8.65%, probabilitas BUY 94.70%, dan forecast consistency 1.00. Angka-angka ini menjelaskan mengapa visualisasi perlu dibaca bersama ranking dan risk score, bukan secara terpisah.

5.7.7 Forecast Panel KHC




Gambar 8. Forecast panel KHC.

KHC memperlihatkan expected return tinggi 10,96% dan buy-low score kuat karena posisinya jauh dari 52-week high. Namun, max drawdown historis sangat besar dan classifier historisnya tidak stabil. Visualisasi forecast panel mendukung interpretasi bahwa KHC adalah tactical opportunity: potensi rebound ada, tetapi risiko strukturalnya lebih besar dibanding core holding. Karena itu sinyalnya HOLD, bukan BUY agresif.

Ringkasan numerik KHC: harga terakhir 23.23, prediksi harga 6 bulan 25.77, ensemble return 10.96%, TimesFM return 4.83%, RF return 17.89%, CatBoost return 9.84%, probabilitas BUY 90.64%, dan forecast consistency 1.00. Angka-angka ini menjelaskan mengapa visualisasi perlu dibaca bersama ranking dan risk score, bukan secara terpisah.

5.7.8 Forecast Panel KO




Gambar 9. Forecast panel KO.

KO menunjukkan karakter defensif dengan volatilitas rendah dan classifier historis kuat, tetapi expected return hanya 3,05% dan excess return mendekati nol. Forecast panel cenderung stabil tetapi kurang menarik untuk horizon 6 bulan jika dibanding kandidat lain. KO tidak dipilih karena sistem mencari kombinasi return dan risiko, bukan risiko rendah semata.

Ringkasan numerik KO: harga terakhir 79.33, prediksi harga 6 bulan 81.75, ensemble return 3.05%, TimesFM return 0.17%, RF return 3.54%, CatBoost return 4.95%, probabilitas BUY 17.72%, dan forecast consistency 1.00. Angka-angka ini menjelaskan mengapa visualisasi perlu dibaca bersama ranking dan risk score, bukan secara terpisah.

5.7.9 Forecast Panel MCO




Gambar 10. Forecast panel MCO.

MCO menjadi return driver utama dengan expected return 16,30% dan expected excess return 13,48%. Forecast panel menunjukkan RF dan CatBoost cukup optimistis, sedangkan TimesFM lebih moderat. Posisi harga yang tidak terlalu dekat 52-week high memberi ruang upside, tetapi stress test 2022 menunjukkan sensitivitas terhadap rate shock. Oleh karena itu, MCO dipilih dengan bobot maksimum 25% tetapi tidak boleh melebihi cap risiko.

Ringkasan numerik MCO: harga terakhir 443.83, prediksi harga 6 bulan 516.17, ensemble return 16.30%, TimesFM return 6.16%, RF return 19.81%, CatBoost return 21.72%, probabilitas BUY 91.25%, dan forecast consistency 1.00. Angka-angka ini menjelaskan mengapa visualisasi perlu dibaca bersama ranking dan risk score, bukan secara terpisah.

5.7.10 Forecast Panel OXY



Gambar 11. Forecast panel OXY.

OXY memiliki ensemble return negatif -13,76%, probabilitas BUY sangat rendah 4,33%, volatilitas tertinggi, dan max drawdown paling ekstrem. Forecast panel menunjukkan risiko penurunan lebih dominan daripada peluang rebound. Walaupun OXY pernah memiliki return historis 6 bulan tinggi, model tidak melihat prospek 6 bulan ke depan yang cukup baik. Saham ini dieliminasi karena tidak sesuai dengan prinsip risk-aware.

Ringkasan numerik OXY: harga terakhir 57.37, prediksi harga 6 bulan 49.47, ensemble return -13.76%, TimesFM return -2.22%, RF return -21.18%, CatBoost return -16.32%, probabilitas BUY 4.33%, dan forecast consistency 0.00. Angka-angka ini menjelaskan mengapa visualisasi perlu dibaca bersama ranking dan risk score, bukan secara terpisah.

6. Pembahasan Lanjutan

6.1 Interpretasi Saham Terpilih

1. MCO dipilih sebagai return driver karena expected return dan expected excess return tertinggi, tetapi bobotnya dibatasi 25% karena risiko rate shock.
2. AAPL dipilih sebagai core holding karena ranking score tertinggi, probabilitas BUY sangat tinggi, likuiditas besar, dan risk score rendah.
3. GOOGL dipilih sebagai growth exposure dengan probabilitas BUY tinggi, tetapi bobotnya dikontrol karena volatilitas relatif tinggi.
4. CB dipilih sebagai stabilizer risiko karena risk score sangat rendah dan exposure sektor Insurance memberi diversifikasi.
5. KHC dipilih sebagai tactical opportunity karena expected return dan buy-low score tinggi, tetapi diberi sinyal HOLD karena risiko historis dan drawdown besar.

6.2 Interpretasi Saham Tidak Terpilih

AXP tidak terpilih karena probabilitas BUY latest lebih rendah daripada kandidat final. KO tidak terpilih karena expected return dan expected excess return kurang menarik meskipun defensif. BAC, CVX, dan OXY tidak terpilih karena expected return negatif atau risk-return profile yang tidak sesuai. Keputusan ini menunjukkan bahwa sistem tidak hanya mengejar saham populer, tetapi menyeleksi berdasarkan kombinasi return, risiko, dan kekuatan sinyal.

6.3 Feature Importance

Feature	Avg Importance
rolling_std_60	11.7462
close_to_52w_low	10.3012
dollar_volume_20	9.0390
close_to_52w_high	6.0576
obv	3.2875
price_position_252d	2.8916
rolling_std_20	2.6228
sma_100	2.3369
adx_14	2.3115
atr_14	2.1828
sharpe_60	1.8389
macd_signal	1.4530

Tabel 12. Feature importance rata-rata tertinggi.

Feature importance memperlihatkan bahwa model banyak memperhatikan volatilitas 60 hari, posisi harga terhadap 52-week low/high, likuiditas, dan momentum. Ini konsisten dengan logika bisnis investasi: saham dengan return menarik tetapi volatilitas ekstrem perlu diberi penalti, sedangkan saham likuid lebih layak untuk modal besar. Fitur `close_to_52w_low` dan `price_position_252d` juga menghubungkan model dengan instruksi soal tentang BUY saat lowest dan HOLD/sell saat highest.

6.4 Analisis Bisnis dan Manajerial

Dari sisi manajerial, output model sebaiknya digunakan sebagai bahan awal rapat komite investasi. Ranking saham menunjukkan prioritas analisis, allocation score menunjukkan bobot awal, dan stress test menunjukkan risiko skenario. Komite tetap perlu memeriksa berita perusahaan, laporan keuangan terbaru, kondisi makro, valuasi, dan risiko kurs sebelum eksekusi. Dengan demikian, AI berfungsi sebagai alat bantu keputusan yang mempercepat analisis dan membuat proses seleksi lebih transparan.

1. Model dapat dijalankan ulang mingguan atau bulanan untuk memperbarui ranking dan bobot.
2. Dashboard operasional sebaiknya menampilkan ranking score, expected return, BUY probability, risk score, sector exposure, dan perubahan bobot dari periode sebelumnya.
3. Risk limit perlu ditetapkan, misalnya maksimum bobot 25% per saham dan batas maksimum sektor.
4. Rebalancing tidak boleh terlalu sering karena biaya transaksi, pajak, slippage, dan kurs IDR/USD dapat mengurangi return aktual.
5. Portofolio harus dipantau terhadap benchmark eksternal seperti SPY, BRK-B, dan QQQ pada eksperimen lanjutan.

6.5 Validitas, Keterbatasan, dan Risiko Praktis

Eksperimen ini valid sebagai simulasi akademik, tetapi belum cukup untuk dijadikan keputusan investasi aktual tanpa validasi lanjutan. Keterbatasannya mencakup tidak adanya data fundamental, biaya transaksi, pajak, kurs, slippage, dan benchmark eksternal numerik. Selain itu, saham bersifat non-stationary sehingga pola masa lalu dapat berubah ketika terjadi krisis, perubahan suku bunga, rotasi sektor, atau perubahan sentimen pasar.

1. Risiko model: prediksi dapat bias ketika rezim pasar berubah.
2. Risiko data: data harga historis tidak memuat informasi fundamental dan sentimen berita.
3. Risiko eksekusi: harga realisasi dapat berbeda dari harga model karena slippage dan spread.
4. Risiko mata uang: return dalam USD dapat berubah setelah dikonversi ke IDR.
5. Risiko regulasi dan pajak: investasi lintas negara memerlukan perhitungan net return setelah pajak dan biaya.
6. Risiko konsentrasi: MCO sebagai return driver perlu dipantau agar tidak menjadi sumber kerugian dominan saat rate shock.

6.6 Analisis Akademik Berbasis Literatur dan Sumber Pendukung

Bagian ini ditambahkan untuk memperdalam pembahasan laporan agar tidak hanya mendeskripsikan hasil eksperimen, tetapi juga mengaitkan hasil tersebut dengan literatur akademik dan sumber teknis yang relevan. Pendalaman ini penting karena laporan UAS pada level magister perlu menunjukkan hubungan antara keputusan teknis dalam pipeline AI dan dasar teoritis yang mendukungnya.

6.6.1 Analisis Dataset dan Kualitas Data

Dataset raw per saham terdiri dari 10 file OHLCV harian, yaitu AAPL, AXP, BAC, CB, CVX, GOOGL, KHC, KO, MCO, dan OXY. Setiap file memiliki rentang waktu 2 Januari 2018 sampai 8 Juni 2026 dengan 2.119 observasi. Struktur ini relevan untuk eksperimen time series karena setiap ticker memiliki panjang historis yang sama. Keceragaman panjang observasi mengurangi bias akibat perbedaan ketersediaan data antar saham, terutama ketika model membandingkan return, volatilitas, drawdown, dan posisi harga pada horizon yang sama.

Secara sumber data, pipeline menggunakan data yang diambil melalui yfinance, yaitu pustaka Python yang menyediakan akses terhadap data historis pasar dari Yahoo Finance. yfinance sesuai untuk eksperimen akademik karena mudah direplikasi dan mendukung pengambilan data OHLCV, tetapi tetap perlu diperlakukan sebagai sumber data sekunder. Artinya, hasil eksperimen sebaiknya tidak langsung dipakai sebagai keputusan investasi aktual tanpa validasi ulang terhadap data resmi broker, exchange, atau data vendor berlisensi (yfinance, 2026).

Dataset all_stocks.csv berfungsi sebagai panel data gabungan dalam format long, yaitu satu baris merepresentasikan kombinasi tanggal dan ticker. Format ini tepat untuk eksperimen multi-saham karena memudahkan feature engineering lintas ticker, validasi jumlah observasi, serta integrasi dengan output ranking. Dataset features_all.csv memperluas data raw menjadi fitur prediktif seperti return, moving average, momentum, volatilitas, liquidity proxy, dan posisi terhadap rentang 52 minggu. Dataset modeling_dataset.csv adalah versi final yang sudah menghapus baris yang belum memiliki fitur lengkap atau target forward return, sehingga lebih aman untuk pelatihan model.

Dari sisi kualitas data, jumlah observasi yang sama tidak berarti seluruh risiko data hilang. Harga saham dapat dipengaruhi oleh corporate action, stock split, dividen, perubahan sektor, perubahan rezim suku bunga, dan kejadian makro yang tidak selalu tertangkap dalam OHLCV. Karena itu, laporan ini perlu menekankan bahwa dataset harga historis hanya merepresentasikan perilaku pasar masa lalu, bukan seluruh informasi bisnis perusahaan. Pemahaman ini sejalan dengan pandangan efficient market hypothesis yang menyatakan bahwa harga pasar berusaha merefleksikan informasi yang tersedia, sehingga prediksi berbasis harga historis secara inheren sulit dan tidak boleh diklaim sebagai kepastian (Fama, 1970).

6.6.2 Analisis Preprocessing dan Pencegahan Data Leakage

Preprocessing pada laporan ini memiliki fungsi metodologis yang penting karena data saham bersifat berurutan secara waktu. Karena target utama adalah return 120 trading days ke depan, maka pembagian data tidak boleh dilakukan secara random. Random split akan mencampur data masa depan ke dalam training set dan dapat menghasilkan metrik yang tampak baik tetapi tidak realistis. Oleh karena itu, time-based split dan walk-forward validation lebih sesuai untuk forecasting karena meniru kondisi nyata: pada saat model membuat prediksi, hanya informasi historis yang tersedia.

Perhitungan rolling features seperti rolling_std_60, moving average, ATR, MACD, dan posisi 52 minggu harus dibangun hanya dari data masa lalu sampai tanggal observasi. Target return 20D, 60D, dan 120D memang dihitung dari harga masa depan, tetapi hanya digunakan sebagai label saat training dan evaluasi, bukan sebagai input. Pemisahan ini merupakan inti pencegahan data leakage dalam

financial machine learning. Praktik ini sejalan dengan prinsip rolling forecasting origin pada evaluasi deret waktu, yaitu origin prediksi digeser maju dan akurasi dihitung dari beberapa test set out-of-sample (Hyndman & Athanasopoulos, 2021).

Dalam dokumen ini, preprocessing tidak hanya bersifat teknis, tetapi menjadi mekanisme validasi akademik. Urutan proses pengumpulan data, penyatuan, pengurutan waktu, validasi missing value, pembentukan fitur, pembentukan target, dan pembagian train-test menunjukkan bahwa eksperimen dirancang untuk menjaga hubungan sebab-akibat temporal. Dengan demikian, hasil prediksi tidak dibangun dari informasi yang seharusnya belum diketahui pada tanggal prediksi.

6.6.3 Analisis Feature Engineering dan Makna Ekonominya

Feature engineering pada eksperimen ini dapat dibaca sebagai upaya menerjemahkan data harga mentah menjadi sinyal ekonomi yang dapat dipahami model. Return features menangkap perubahan harga historis dalam beberapa horizon; trend features membaca arah pergerakan harga; momentum indicators mencoba mengukur kekuatan tren; volatility features mengukur ketidakpastian; liquidity features membaca kapasitas pasar untuk menyerap transaksi; dan 52-week position features membantu mengidentifikasi apakah harga sedang dekat dengan titik ekstrem historis.

Feature importance rata-rata menunjukkan bahwa `rolling_std_60`, `close_to_52w_low`, `dollar_volume_20`, `close_to_52w_high`, `OBV`, dan `price_position_252d` menjadi fitur yang paling dominan. Temuan ini dapat diinterpretasikan secara bisnis: model tidak hanya mengejar saham dengan return tinggi, tetapi juga memperhatikan risiko fluktuasi, posisi harga relatif terhadap rentang historis, dan tingkat likuiditas. Hal ini konsisten dengan prinsip portofolio bahwa keputusan investasi perlu mempertimbangkan hubungan return dan risiko, bukan return secara terpisah (Markowitz, 1952).

`rolling_std_60` sebagai fitur terpenting menunjukkan bahwa model sangat sensitif terhadap volatilitas dua sampai tiga bulan terakhir. Saham dengan volatilitas tinggi dapat memberi peluang return besar, tetapi juga meningkatkan ketidakpastian realisasi. `close_to_52w_low` dan `close_to_52w_high` memberi konteks apakah saham sedang berada pada area potensi rebound atau area yang sudah relatif mahal. `dollar_volume_20` penting karena portofolio simulasi menggunakan modal Rp1 triliun; tanpa memperhatikan likuiditas, rekomendasi bobot dapat terlihat menarik secara model tetapi sulit dieksekusi pada pasar nyata tanpa slippage.

6.6.4 Analisis Model AI yang Digunakan

TimesFM 2.5 digunakan sebagai time-series foundation model. Secara konseptual, TimesFM relevan karena dirancang sebagai model forecasting berbasis decoder-only yang dilatih pada korpus deret waktu besar dan dapat digunakan pada berbagai granularitas serta horizon prediksi (Das et al., 2024; Google Research, 2024). Dalam eksperimen ini, TimesFM berperan sebagai anchor yang lebih konservatif karena proyeksinya pada beberapa saham tidak seekstrem RandomForest atau CatBoost. Peran ini penting untuk mengurangi risiko model tabular terlalu agresif membaca pola historis.

RandomForestRegressor digunakan untuk menangkap hubungan non-linear antar fitur. Random Forest bekerja dengan membangun banyak decision tree pada sub-sample data dan menggabungkan prediksi untuk meningkatkan akurasi serta mengendalikan overfitting (Breiman, 2001; scikit-learn, 2026). Pada

data saham, pendekatan ini berguna karena hubungan antara momentum, volatilitas, liquidity, dan forward return jarang berbentuk linear sederhana. Namun, RandomForest tetap memiliki keterbatasan karena tidak secara eksplisit memahami urutan waktu seperti model time series murni.

CatBoostRegressor digunakan sebagai model gradient boosting berbasis decision tree. CatBoost relevan karena boosting membangun model secara bertahap untuk memperbaiki error model sebelumnya. Literatur CatBoost menekankan ordered boosting untuk mengurangi prediction shift dan leakage tertentu pada boosting, serta kemampuan menangani struktur fitur secara efisien (Prokhorenkova et al., 2018; CatBoost, 2026). Dalam eksperimen ini, CatBoost cenderung memberi proyeksi lebih agresif pada saham tertentu seperti MCO dan AAPL, sehingga perlu diseimbangkan oleh TimesFM dan risk score.

CatBoostClassifier digunakan untuk mengestimasi probabilitas return 120D positif. Rata-rata accuracy classifier sebesar 51,87% dan ROC-AUC sebesar 58,15% menunjukkan bahwa classifier tidak cukup kuat sebagai penentu tunggal keputusan investasi. Namun, dalam konteks saham yang noisy, sinyal probabilistik moderat masih dapat berguna ketika digabungkan dengan expected return, risk score, liquidity score, dan benchmark. ROC-AUC sendiri mengukur kemampuan ranking classifier terhadap kelas positif dan negatif, sehingga lebih informatif daripada accuracy ketika distribusi kelas tidak seimbang (scikit-learn, 2026).

Ensemble forecast digunakan untuk menggabungkan TimesFM, RandomForest, dan CatBoostRegressor. Secara akademik, ensemble lebih defensibel karena mengurangi ketergantungan pada satu model. Dalam laporan ini, TimesFM diberi bobot tetap 30%, sedangkan RandomForest dan CatBoost disesuaikan menggunakan inverse RMSE. Model dengan RMSE lebih rendah memperoleh bobot lebih besar. Mekanisme ini membuat ensemble adaptif terhadap performa historis, tetapi tetap mempertahankan anchor time-series agar hasil tidak sepenuhnya didominasi model tabular.

6.6.5 Analisis Evaluasi Model dan Implikasi Akurasi

Rata-rata evaluasi Ensemble pada test set menghasilkan MAE 0,1606, RMSE 0,1965, dan DSTAT 57,49%. Angka ini perlu dibaca secara hati-hati. Directional accuracy di atas 50% menunjukkan kemampuan model sedikit lebih baik daripada tebakan arah secara acak, tetapi belum cukup untuk menyatakan model sangat akurat. Dalam forecasting finansial, hasil seperti ini lebih tepat diposisikan sebagai decision support signal, bukan mekanisme prediksi absolut.

Perbedaan performa antar saham juga penting. KO memiliki DSTAT tertinggi sebesar 67,73%, sedangkan MCO hanya 47,81% walaupun expected return-nya paling tinggi. Ini menunjukkan bahwa ranking portofolio tidak boleh hanya membaca satu metrik evaluasi. Saham dengan proyeksi return tinggi tetapi DSTAT rendah perlu dibatasi bobotnya melalui risk-aware allocation. Sebaliknya, saham dengan akurasi arah baik tetapi expected return rendah seperti KO dapat tetap tidak terpilih jika kontribusi return portofolio kurang memadai.

RMSE yang lebih tinggi daripada MAE menunjukkan adanya error besar pada sebagian observasi, yang umum terjadi pada data saham karena adanya shock pasar, earnings surprise, perubahan suku bunga, dan sentimen makro. Oleh karena itu, penggunaan MAE, RMSE, DSTAT, classifier

probability, dan stress test secara bersamaan lebih kuat dibanding hanya melaporkan satu angka performa. Praktik ini juga sejalan dengan pendekatan evaluasi model di scikit-learn yang menyediakan metrik berbeda untuk memahami kualitas prediksi dari sisi error regresi maupun kemampuan klasifikasi (scikit-learn, 2026).

6.6.6 Analisis Forecast Panel Saham Terpilih dan Tidak Terpilih

Forecast panel tidak hanya berfungsi sebagai visualisasi, tetapi sebagai alat audit keputusan model. Pada AAPL, GOOGL, CB, MCO, dan KHC, visualisasi menunjukkan alasan mengapa saham masuk portofolio: proyeksi return positif, probabilitas BUY relatif kuat, atau kontribusi diversifikasi. AAPL berperan sebagai core holding karena kombinasi ranking score tertinggi, likuiditas sangat besar, dan probabilitas BUY 98,07%. MCO berperan sebagai return driver karena expected return 16,30%, tetapi DSTAT yang rendah dan risiko rate shock membuat bobotnya perlu dibatasi.

GOOGL dipilih karena probabilitas BUY 94,70% dan expected return 6,43%, tetapi volatilitas 60D sebesar 2,29% membuatnya tidak diberi bobot terlalu dominan. CB dipilih sebagai stabilizer karena risk score rendah dan proyeksi return moderat. KHC dipilih sebagai tactical opportunity karena expected return 10,96% dan buy-low score tinggi, tetapi status HOLD menunjukkan bahwa saham ini memiliki risiko historis besar, terutama max drawdown -72,00%.

AXP, KO, BAC, CVX, dan OXY tidak terpilih karena alasan yang berbeda. AXP memiliki expected return positif 7,19%, tetapi probabilitas BUY hanya 28,72%, sehingga sinyal classifier tidak mendukung. KO stabil dan defensive, tetapi expected excess return hanya 0,23%, sehingga kontribusi return relatif kecil. BAC, CVX, dan OXY memiliki ensemble return negatif, dengan OXY menjadi kandidat terlemah karena expected return -13,76%, probabilitas BUY 4,33%, volatilitas tertinggi, dan max drawdown paling ekstrem. Dengan demikian, visual forecast panel membantu menjelaskan bahwa seleksi saham bukan sekadar memilih return tertinggi, tetapi kombinasi return, confidence, risiko, dan diversifikasi.

6.6.7 Analisis Ranking, Alokasi Bobot, dan Teori Portofolio

Formula ranking menggunakan kombinasi expected return, expected excess return, DSTAT, Buy Probability, liquidity score, risk score, buy-low score, dan hold-highest score. Pendekatan ini sesuai dengan prinsip bahwa portofolio harus menyeimbangkan return dan risiko. Markowitz (1952) menekankan bahwa risiko portofolio tidak hanya berasal dari risiko masing-masing aset, tetapi juga dari bagaimana aset-aset tersebut dikombinasikan. Walaupun laporan ini belum menghitung covariance matrix penuh seperti mean-variance optimization klasik, logika risk-aware allocation sudah mengarah pada prinsip yang sama: return tinggi harus dikontrol dengan risiko dan diversifikasi.

Alokasi final menghasilkan MCO 25,00%, AAPL 19,72%, GOOGL 16,66%, CB 18,43%, dan KHC 20,19%. Bobot MCO dibatasi pada 25% meskipun expected return-nya tertinggi. Keputusan ini tepat secara manajerial karena saham return driver dapat menjadi sumber kerugian dominan ketika skenario pasar berubah. Dalam konteks investasi institusional, pembatasan bobot maksimum merupakan bentuk risk limit agar portofolio tidak terlalu bergantung pada satu sumber alpha.

Projected return 9,95% selama 6 bulan dan projected profit Rp99,55 miliar perlu dipahami sebagai expected value berbasis model, bukan janji hasil. Karena pasar saham bersifat adaptif dan dipengaruhi informasi baru, hasil prediksi harus disertai monitoring, rebalancing, dan validasi benchmark. Pandangan ini konsisten dengan Fama (1970) yang menekankan bahwa harga pasar merefleksikan informasi tersedia, sehingga strategi prediktif harus diuji secara ketat dan tidak diasumsikan selalu mengalahkan pasar.

6.6.8 Analisis Benchmark, Sector Exposure, dan Stress Test

Benchmark internal menunjukkan bahwa risk-aware selected portfolio menghasilkan expected return 9,95%, lebih tinggi dibanding equal-weight 10 kandidat sebesar 2,82% dan equal-weight top 5 sebesar 9,00%. Selisih ini menunjukkan bahwa alokasi bobot memberi nilai tambah dibanding sekadar memilih saham lalu membaginya rata. Namun, benchmark internal belum cukup untuk menyimpulkan keunggulan pasar. Untuk eksperimen lanjutan, portofolio perlu dibandingkan dengan SPY sebagai proxy S&P 500, QQQ sebagai proxy teknologi/growth, serta BRK-B sebagai pembanding yang relevan dengan konteks Warren Buffett.

Sector exposure portofolio terdiri dari Financial Services 25,00%, Consumer Staples 20,19%, Technology 19,72%, Insurance 18,43%, dan Communication Services 16,66%. Komposisi ini relatif tersebar, tetapi tetap memiliki ketergantungan pada saham-saham berkualitas besar di Amerika Serikat. Dari perspektif bisnis, diversifikasi sektor ini membantu mengurangi risiko konsentrasi, namun belum sepenuhnya menghilangkan risiko makro karena seluruh aset tetap berada pada pasar ekuitas AS dan sebagian besar menggunakan mata uang USD.

Stress test memberikan pembacaan risiko yang lebih realistis. Pada COVID crash proxy, portofolio turun -34,04%, tetapi masih lebih baik daripada equal-weight universe yang turun -42,98%. Pada 2022 rate shock proxy, portofolio turun -19,43% sementara universe naik 0,76%, sehingga portofolio underperform secara signifikan. Ini menunjukkan bahwa strategi yang tampak baik pada expected return dapat gagal pada rezim suku bunga tertentu. Pada recent test window, portofolio menghasilkan 10,98% tetapi masih sedikit di bawah universe 11,98%. Dengan demikian, stress test membuktikan bahwa model perlu dipakai bersama risk governance, bukan sebagai mesin keputusan otomatis.

6.6.9 Analisis Implikasi Manajerial Berbasis Business AI

Dalam konteks mata kuliah Kecerdasan Artifisial pada Bisnis, kontribusi utama eksperimen ini bukan hanya pembuatan model forecasting, tetapi perancangan alur decision support. AI digunakan untuk menyaring kandidat, menghasilkan sinyal return, menghitung confidence, mengukur risiko, membangun ranking, dan menerjemahkan output model menjadi bobot portofolio. Dengan kata lain, model AI berperan sebagai sistem pendukung keputusan investasi, bukan pengganti penuh manajer investasi.

Secara operasional, hasil model sebaiknya digunakan dalam rapat komite investasi sebagai bahan awal diskusi. Analisis dapat memeriksa saham dengan ranking tinggi, menguji apakah sinyal model didukung oleh kondisi fundamental, memeriksa berita terbaru, serta mengevaluasi apakah sektor tertentu sedang menghadapi risiko makro. Keputusan akhir tetap perlu human oversight karena model berbasis harga

historis tidak memahami secara lengkap perubahan regulasi, geopolitik, laporan keuangan terbaru, ataupun perubahan strategi perusahaan.

Untuk implementasi bisnis, sistem dapat dijalankan ulang secara mingguan atau bulanan. Dashboard perlu menampilkan perubahan ranking score, expected return, Buy Probability, risk score, sector exposure, dan perubahan bobot dari periode sebelumnya. Selain itu, sistem harus memiliki alert jika terjadi peningkatan volatilitas, perubahan drawdown ekstrem, atau penurunan probabilitas BUY pada saham yang sedang dipegang. Penggunaan AI yang baik dalam bisnis bukan hanya menghasilkan prediksi, tetapi juga menyediakan mekanisme monitoring, audit, dan kontrol risiko.

6.6.10 Analisis Risiko Praktis dan Rekomendasi Validasi Lanjutan

Risiko praktis terbesar dari eksperimen ini adalah perbedaan antara gross expected return dan net realized return. Laporan menggunakan modal Rp1 triliun dan saham AS, sehingga return aktual investor Indonesia akan dipengaruhi kurs IDR/USD, biaya konversi, biaya broker, pajak dividen, pajak capital gain sesuai yurisdiksi, bid-ask spread, serta slippage. Karena itu, projected profit Rp99,55 miliar perlu dikoreksi dalam eksperimen lanjutan menggunakan simulasi biaya transaksi dan nilai tukar.

Risiko kedua adalah model risk. Model yang dilatih pada data 2018-2026 dapat membaca pola historis, tetapi belum tentu robust terhadap rezim baru. Ketika inflasi, suku bunga, earnings cycle, atau sentimen sektor berubah, hubungan antara fitur teknikal dan return masa depan dapat melemah. Oleh karena itu, retraining berkala, monitoring out-of-sample, dan pembandingan terhadap benchmark eksternal wajib dilakukan sebelum sistem digunakan pada skenario nyata.

Risiko ketiga adalah keterbatasan input. Dataset belum memasukkan data fundamental seperti revenue growth, margin, debt ratio, free cash flow, valuation multiple, EPS surprise, analyst revision, dan sentimen berita. Padahal untuk saham-saham besar seperti AAPL, GOOGL, MCO, dan KHC, faktor fundamental dapat memengaruhi return 6 bulan secara signifikan. Rekomendasi pengembangan paling penting adalah menggabungkan data teknikal dengan data fundamental dan news sentiment sehingga model tidak hanya membaca pola harga, tetapi juga konteks bisnis perusahaan.

7. Kesimpulan

Berdasarkan eksperimen yang telah dilakukan, sistem AI merekomendasikan portofolio MCO, AAPL, GOOGL, CB, KHC dengan expected return 6 bulan 9.95% dan projected profit Rp99.547.339.309 dari modal Rp1 triliun. Rekomendasi ini merupakan hasil gabungan time-series forecasting, machine learning regression, probabilistic classification, risk scoring, dan allocation scoring.

Daftar Pustaka

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32.
<https://doi.org/10.1023/A:1010933404324>

CatBoost. (2026). CatBoost - open-source gradient boosting library. CatBoost official documentation.
<https://catboost.ai/>

Das, A., Kong, W., Sen, R., & Zhou, Y. (2024). A decoder-only foundation model for time-series forecasting. *Proceedings of the 41st International Conference on Machine Learning*, PMLR 235, 10148-10167.

Dorogush, A. V., Ershov, V., & Gulin, A. (2018). CatBoost: gradient boosting with categorical features support. *arXiv:1810.11363*.

Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2), 383-417.

Google Research. (2024). A decoder-only foundation model for time-series forecasting. *Google Research Blog*.

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts.

Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77-91.

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31.

scikit-learn developers. (2026). RandomForestRegressor, model evaluation metrics, mean absolute error, root mean squared error, and ROC-AUC score documentation. *scikit-learn official documentation*. <https://scikit-learn.org/>

Sharpe, W. F. (1966). Mutual fund performance. *The Journal of Business*, 39(1), 119-138.

yfinance. (2026). yfinance Python package and API reference: Download market data from Yahoo Finance. <https://pypi.org/project/yfinance/>

Lampiran

1. Raw dataset tersedia pada folder data/raw per ticker.
2. Dataset gabungan tersedia pada data/processed/all_stocks.csv.
3. Feature dataset tersedia pada data/processed/features_all.csv dan modeling_dataset.csv.
4. Output prediksi, ranking, portofolio, benchmark, sector exposure, dan stress test tersedia pada outputs/tables.
5. Visualisasi forecast panel tersedia pada outputs/figures/forecast_panel_{ticker}.png.
6. Pipeline dapat dijalankan ulang melalui source code project dan notebook eksperimen.
7. Dashboard Rekomendasi Portofolio Saham dapat dilihat pada link berikut: <https://uas-kab-aisyaululasmi.streamlit.app/>
8. Dokumentasi lengkap (source code, dataset, output, dan laporan) dapat dilihat pada link github berikut: https://github.com/Aisyaululasmi/UAS_KAB